

# ベイズ推定に基づく線形回帰

知能システム制御研究室  
学籍番号2011115 佐伯 雄飛


# 目次

1. 背景
2. 推定手法
3. 数値実験
4. まとめ

# 背景

---

# 回帰問題とは



● 観測データ  $D = \{(x_i, y_i); i = 1, 2, \dots, n\}$

観測データ  $D$  から、回帰関数モデル  $y(x)$  を推定し、未知の観測データ  $x$  に対する出力  $y$  を予測することが、回帰問題の目的となる。

# 回帰関数モデル

回帰関数モデルは基底関数の線形結合に基づき，以下のように定義される

$$y(x) = \Phi(x) * w + \varepsilon \quad (1)$$

$\Phi(x)$  :  $x$ の基底関数

$w$  : 基底関数の係数      ←ここを推定する

$\varepsilon$  : 誤差項

# 推定方法

---

# 最小二乗推定

方針：予測誤差の二乗和 $S(w)$ を最小化する $\hat{w}$ を推定値とする

$$S(w) = \varepsilon^T \varepsilon = (y - \Phi w)^T (y - \Phi w) \quad (2)$$

$S(w)$ を $w$ で偏微分して $\hat{w}$ を求める.

$$\frac{dS(w)}{dw} = -\Phi^T y + \Phi^T \Phi w$$

$\frac{dS(w)}{dw} = 0$  のとき

$$\hat{w} = (\Phi^T \Phi)^{-1} \Phi^T y$$

従って、最小二乗推定による予測モデルは,

$$\hat{y} = \Phi \hat{w} = \Phi (\Phi^T \Phi)^{-1} \Phi^T y$$

# 最尤推定

方針：尤度 $P(y|w)$ を最大化する $\hat{w}$ を推定値とする

観測データ $D$ は何かしらの分布 $H$ に基づいて生成されると考え、  
データが発生する確率(尤度)が最大化する場合を考える。

誤差項に正規分布を仮定した際、  
観測値 $y$ は、平均 $\Phi w$ 、分散行列 $\sigma^2 I_n$ の $n$ 次元正規分布に従う。  
よって、尤度は

$$P(y|w) = \mathcal{N}(\Phi w, \sigma^2) \quad (3)$$

→最大化



# 最尤推定

$$P(y|w) = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} \exp \left\{ -\frac{1}{2\sigma^2} (y - \Phi w)^T (y - \Phi w) \right\}$$

両辺の対数を取る

$$\log P(y|w) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{(y - \Phi w)^T (y - \Phi w)}{2\sigma^2}$$

$w$  で微分する

$$\frac{1}{P(y|w)} \frac{dP(y|w)}{dw} = -(\Phi^T y + \Phi^T \Phi w)$$

# 最尤推定

$$\frac{P(y|w)}{dw} = 0 \text{ のときを考えると}$$
$$\hat{w} = (\Phi^T \Phi)^{-1} \Phi^T y$$

従って、最尤推定による予測モデルは、

$$\hat{y} = \Phi \hat{w} = \Phi (\Phi^T \Phi)^{-1} \Phi^T y$$

(最小二乗推定と同じ結果になる)

# MAP推定

方針：  $w$  の事後分布  $P(w|y)$  を最大化する  $\hat{w}$  を推定値とする

$w$  を確率変数として扱いベイズ推定により事後分布  $P(w|y)$  を求める.

ベイズの定理

事後分布

尤度

$$P(w|y) = \frac{P(y|w)P(w)}{P(y)}$$

事前分布

# MAP推定

事前分布と尤度分布は以下のものを導入する.

$$P(w) = \mathcal{N}(0, \alpha^{-1} I_n) \quad (4)$$

$$P(y|w) = \mathcal{N}(\Phi w, \beta^{-1} I_n) \quad (5)$$

よって, 事後確率は以下のように表せる.

$$P(w|y) = \frac{\frac{1}{(2\pi\beta^{-1})^{\frac{n}{2}}} \exp\{-\frac{1}{2\beta^2} (y\Phi w)^T (y - \Phi w)\} \frac{1}{(2\pi\alpha^{-1})^{\frac{n}{2}}} \exp\{-\frac{1}{2\alpha^2} w^T w\}}{P(y)}$$

$P(w|y)$ を最大化する $\hat{w}$ は, 分子( $Z$ とおく)を最大化する $\hat{w}$ と等しい

$$\frac{dZ}{dw} = -\frac{1}{2\beta^{-1}} (-\Phi^T + \Phi^T \Phi w) - \frac{1}{2\alpha^{-1}} w^T w$$

# MAP推定

$\frac{dZ}{dw} = 0$ のときを考えると,

$$\hat{w} = \left( -\frac{\alpha}{\beta} I_n + \Phi^T \Phi \right)^{-1} \Phi^T y$$

従って, MAP推定による予測モデルは,

$$\hat{y} = \Phi \hat{w} = \Phi \left( -\frac{\alpha}{\beta} I_n + \Phi^T \Phi \right)^{-1} \Phi^T y$$

# ベイズ推定

方針：  $w$  の事後分布  $P(w|y)$  を確率分布として区間推定する

MAP推定では、  $P(w|y)$  の最大化を考えたため  $P(y)$  を無視したが、  
ベイズ推定では考える必要がある。

$P(y)$  を周辺化により求める。

$$P(y) = \int P(y|w)P(w)dw$$

$$P(w|y) = \frac{P(y|w)P(w)}{\int P(y|w)P(w)dw}$$

# ベイズ推定

ガウス分布に対するベイズの定理より,

$$P(w|y) = \mathcal{N}(u_N, \Sigma_N) \quad (6)$$

参考文献PRML p90 ガウス分布と周辺分布と条件付き分布を用いて計算する

$$u_N \left( \frac{\alpha}{\beta} I_n + \Phi^T \Phi \right)^{-1} \Phi^T y \quad (7)$$

$$\Sigma_N = (\alpha I_n + \beta \Phi^T \Phi)^{-1} \quad (8)$$

従って, ベイズ推定による予測モデルは,

$$\hat{y} = \Phi \hat{w} = \Phi \left( -\frac{\alpha}{\beta} I_n + \Phi^T \Phi \right)^{-1} \Phi^T y$$
$$\Sigma_N = (\alpha I_n + \beta \Phi^T \Phi)^{-1}$$

# 数値実験

---



# 概要



$D = \{(x.train, y.train); i = 1, 2, \dots, 15\}$  の訓練データに対して,  
最小二乗推定, 最尤推定, MAP推定, ベイズ推定を用いてモデルを作成  
 $D = \{(x.test, y.test); i = 1, 2, \dots, 100\}$  のテストデータに対して予測分布を確認した.

基底関数は以下のものを用いる.

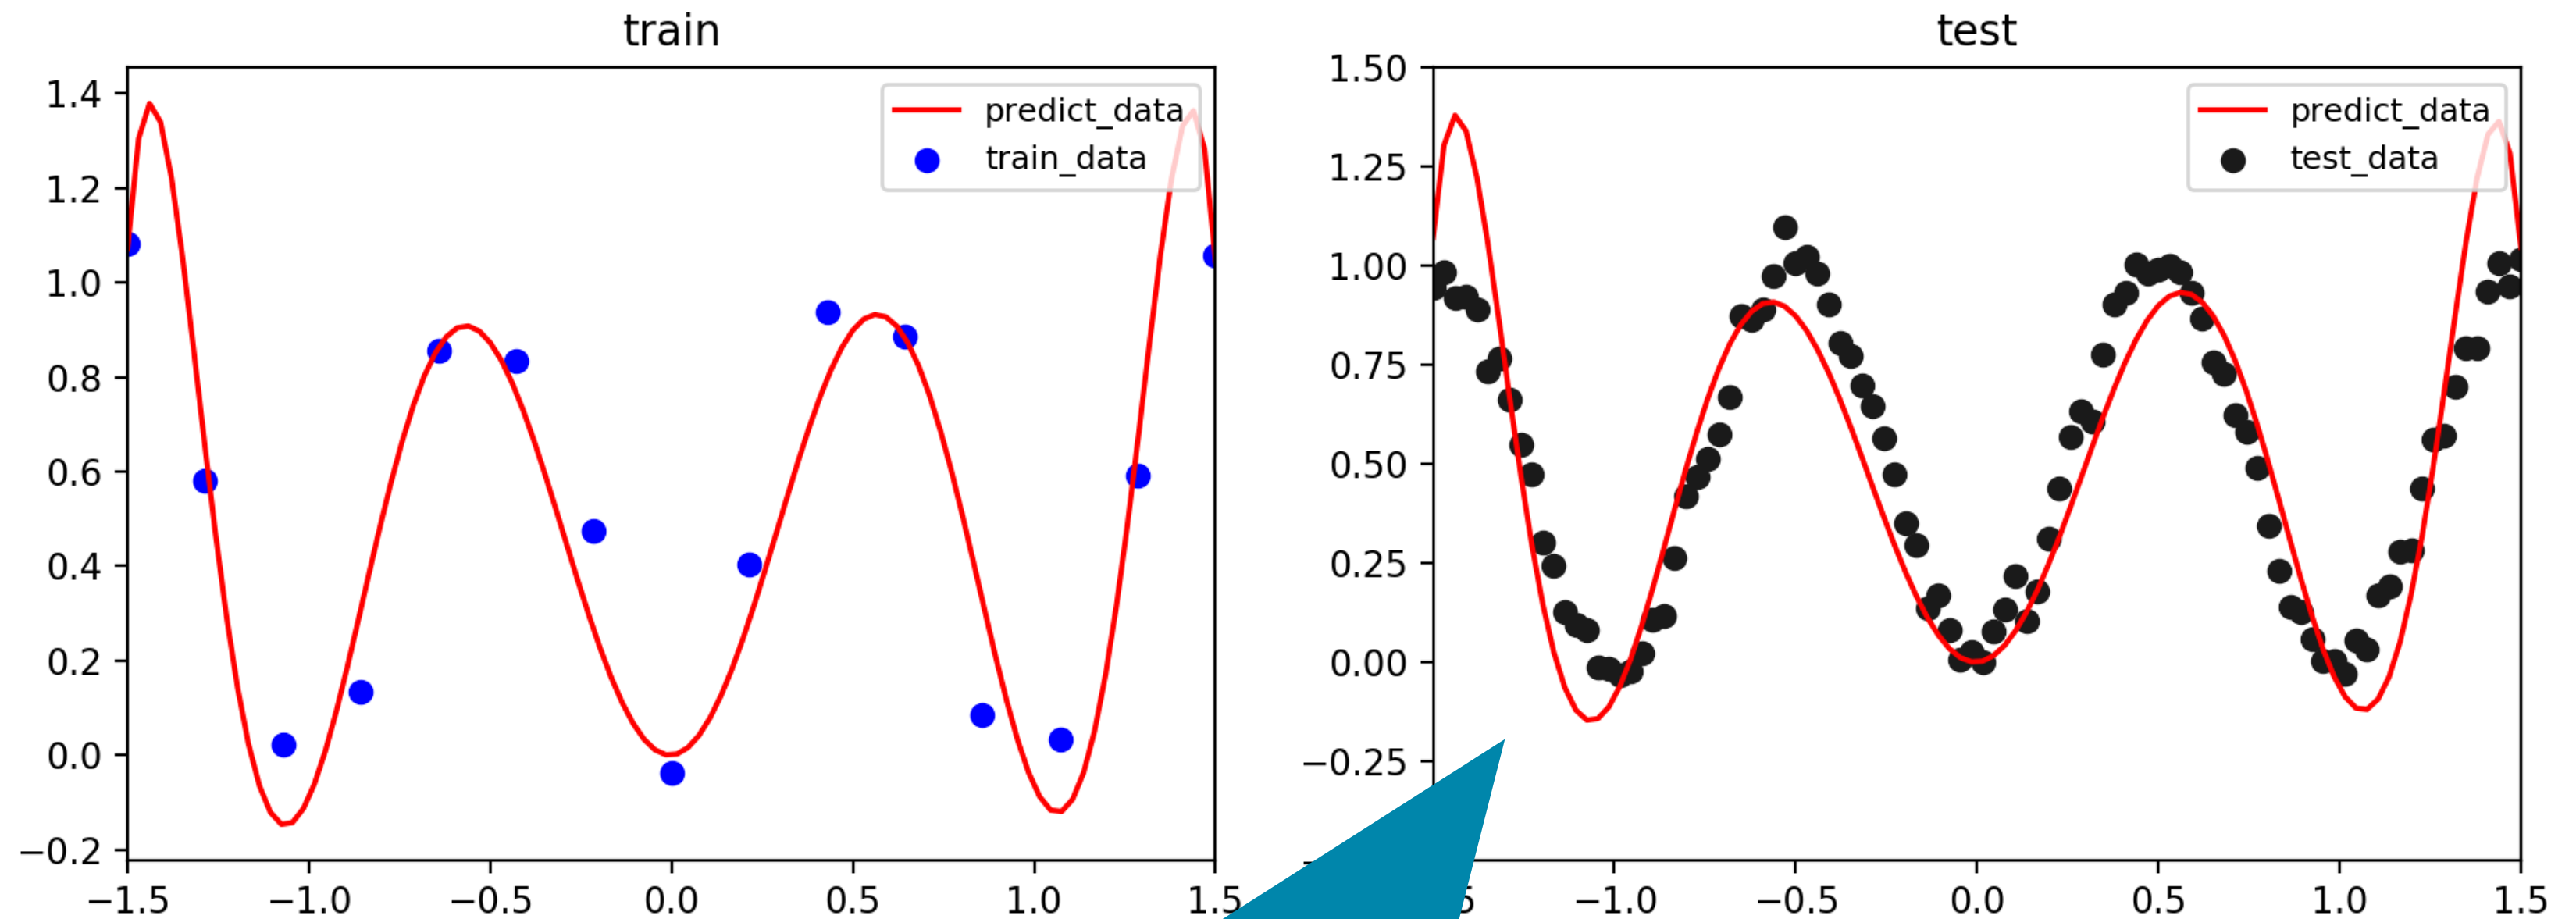
$$f_j(x) = x^j, j = 0, 1, \dots, 9 \quad (10)$$

# 実験結果(最小二乗法, 最尤推定)

訓練データが少ない部分の  
予測精度は下がる.


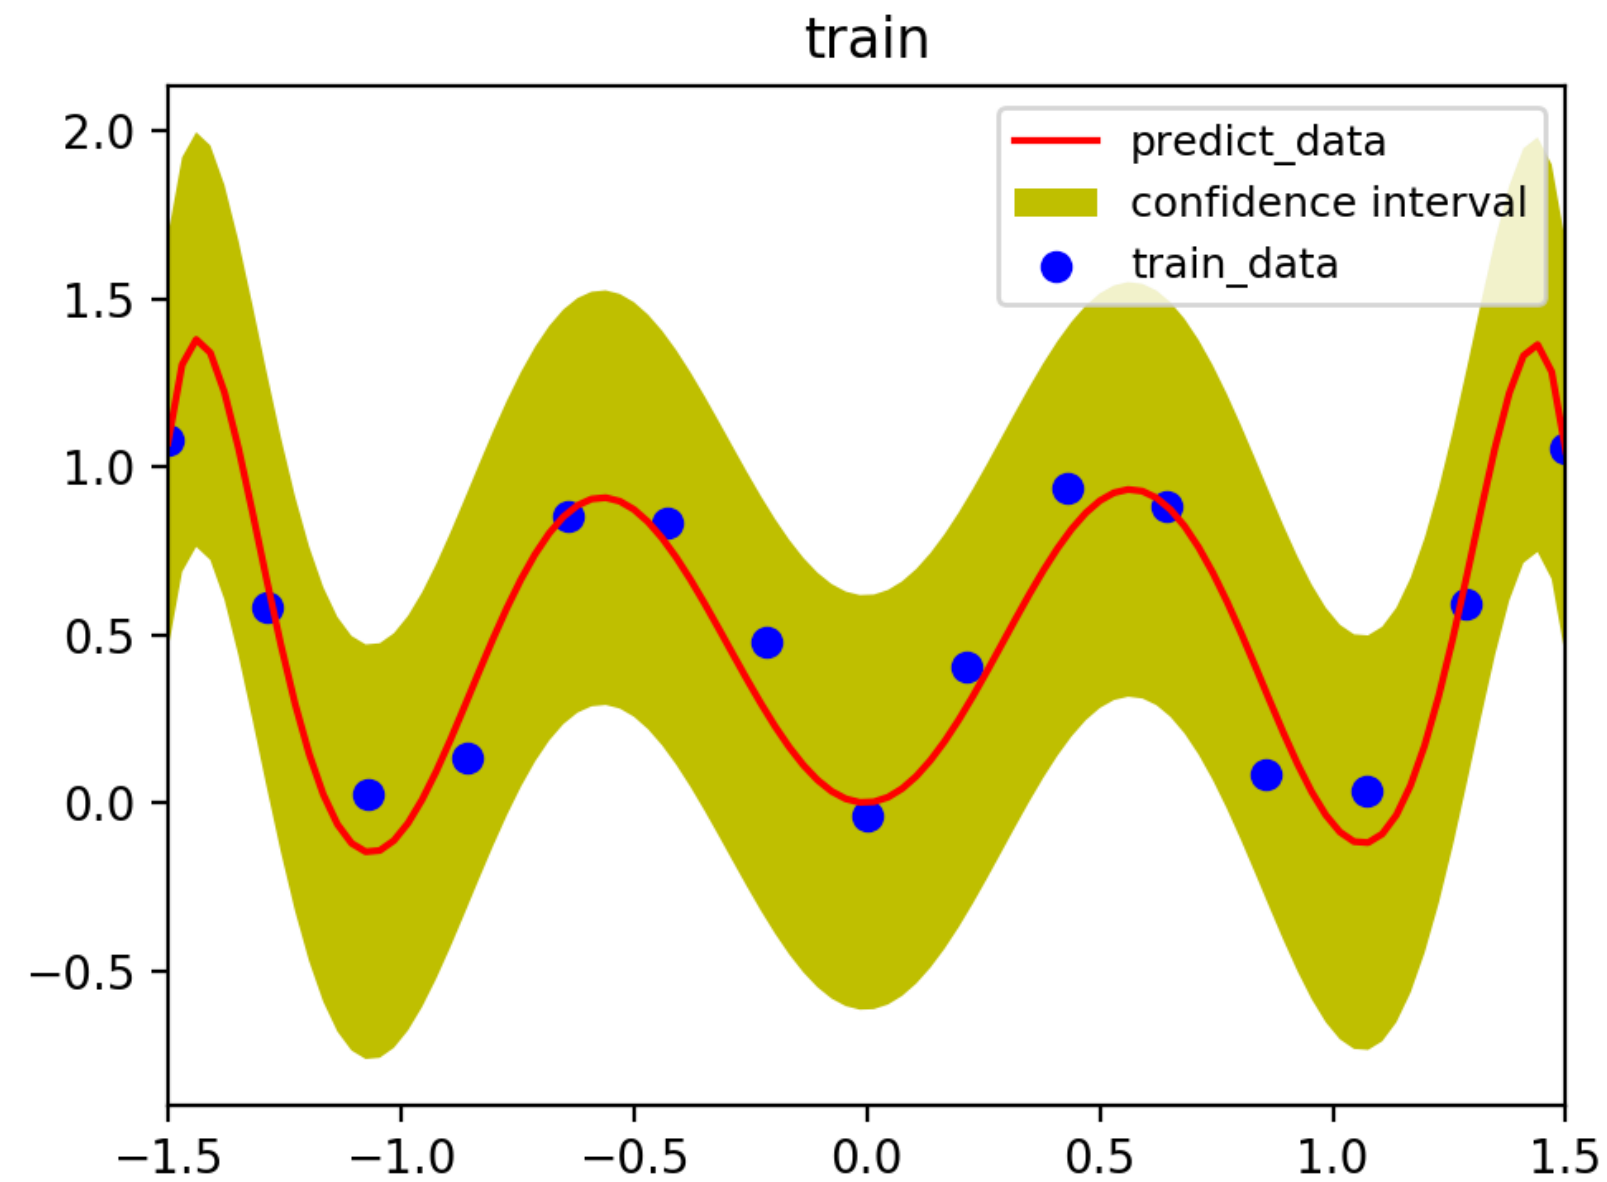


# MAP推定( $\alpha = 10, \beta = 10$ )



大きく外れる部分が減少した.

# ベイズ推定( $\alpha = 10, \beta = 10$ )

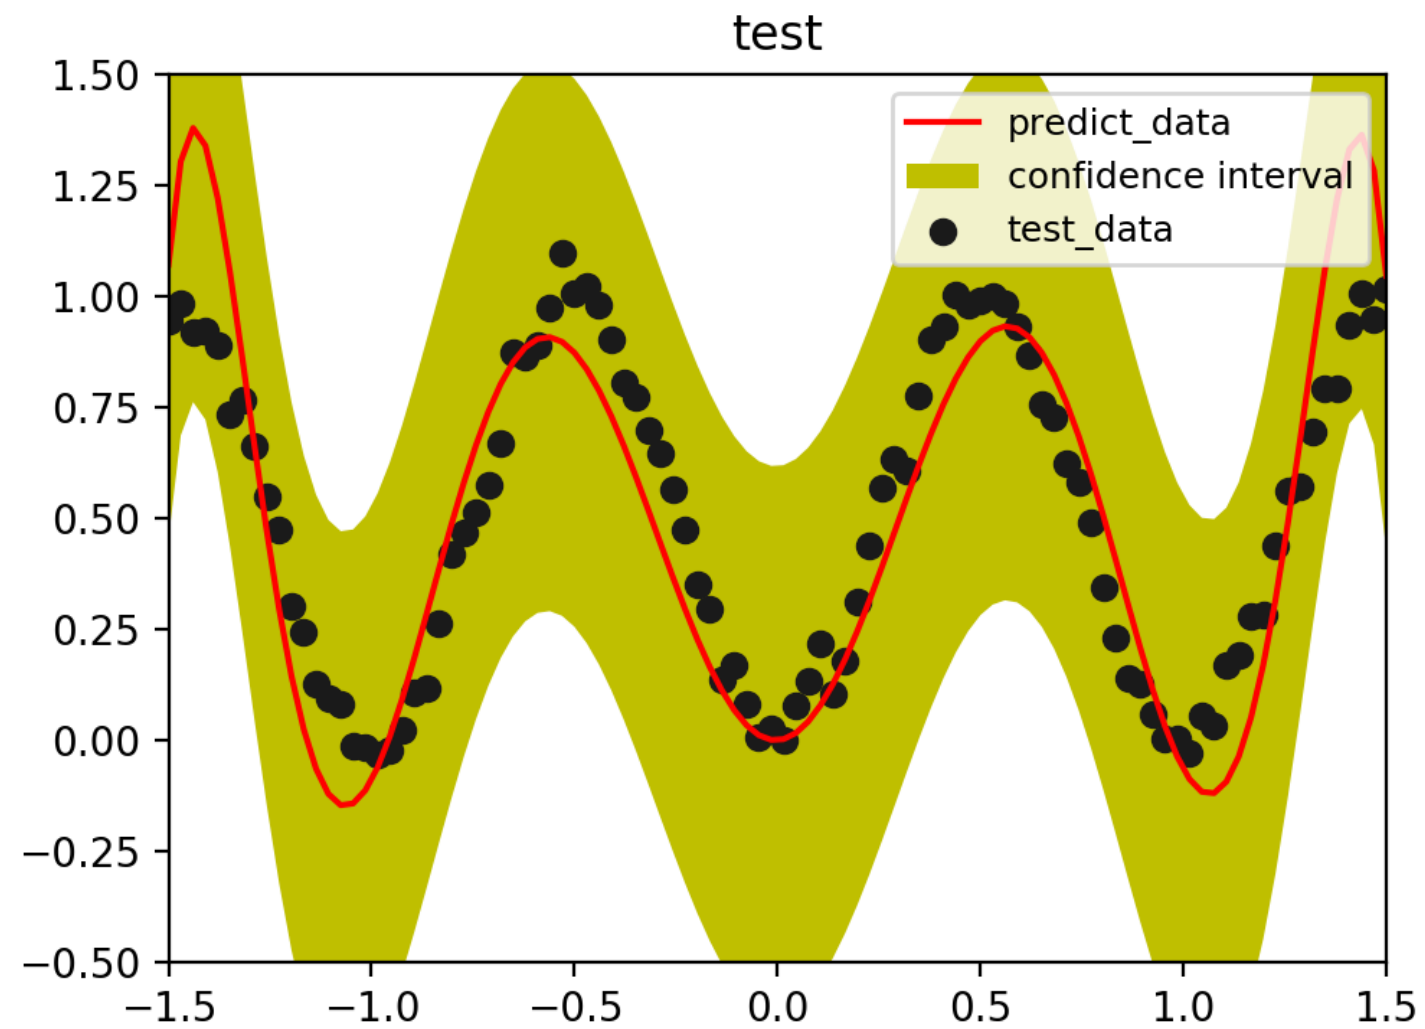


# 決定係数 $R^2$


$$R^2 = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (11)$$

手法	最小二乗推定, 最尤推定	MAP推定
$R^2$	0.760122979	0.769478635

# ベイズ推定( $\beta = 10, 50, 100, 1000$ )




$\beta = 10$




$\beta = 50$

# ベイズ推定( $\beta = 10, 50, 100, 1000$ )



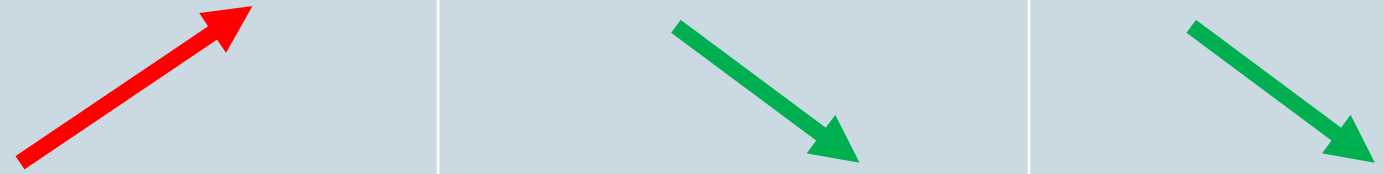
$\beta = 100$



$\beta = 1000$

## MAP推定( $\beta = 10, 50, 100, 1000$ )の $R^2$

$\beta$	10	50	100	1000
$R^2$	0.76947	0.77227	0.769478	0.761849



誤差が小さくなっている。

過学習を起こしている。



# まとめ

---

# まとめ

事前に与えられる情報に応じて、適切に推定方法を変えることが重要であることがわかった.

訓練データが少ない部分について、誤差を小さくすることができなかったことが今後の課題である.